

# HAM10000 Dermoskopik Görüntü Veri Setinde Geleneksel ve Derin Öğrenme Yöntemleriyle Çok Sınıflı Deri Lezyonu Sınıflandırması

Zühtü Hilmi Düzgüner

Bilgisayar Mühendisliği Bölümü, Ankara Üniversitesi, Ankara, Türkiye

**Abstract**—Bu çalışmada, HAM10000 dermoskopik görüntü veri seti üzerinde yedi sınıflı deri lezyonu sınıflandırması gerçekleştirilmiştir. Veri sızıntısını önlemek amacıyla StratifiedGroupKFold yöntemiyle lezyon kimliğine (lesion\_id) dayalı gruplu bölme uygulanmıştır. Geleneksel yöntemler olarak PCA+SMOTE ile k-En Yakın Komşu (k-NN) ve HOG+PCA ile Destek Vektör Makineleri (SVM); derin öğrenme yöntemleri olarak ise ImageNet üzerinde ön-eğitilmiş AlexNet, VGG16 ve ResNet50 mimarileri karşılaştırılmıştır. Sınıf dengesizliğine karşı CrossEntropyLoss ağırlıklandırması, aşırı öğrenmeye karşı veri artırma (data augmentation) ve erken durdurma (sabır=10) uygulanmıştır. Elde edilen bulgular, ResNet50'nin Makro F1 skorunda (%72.36) en yüksek başarıyı gösterirken, klinik açıdan kritik olan melanom duyarlılığında (Recall) VGG16 modelinin (%59.36) daha güvenilir sonuçlar ürettiğini ortaya koymuştur. Geleneksel yöntemler (k-NN: %30.31; SVM: %24.77) derin öğrenme modellerinin belirgin biçimde gerisinde kalmıştır. ResNet50 üzerinde gerçekleştirilen ablasyon çalışması, veri artırma ve sınıf ağırlıklandırmasının model performansına bağımsız ve birleşik katkılarını sayısal olarak ortaya koymuştur.

**Index Terms**—ablasyon çalışması, deri kanseri tespiti, derin öğrenme, dermoskopi, HAM10000, melanom, ResNet50, sınıf dengesizliği, transfer öğrenme, VGG16.

## I. GİRİŞ

Melanom, en ölümcül deri kanseri türlerinden biri olup erken evre tespiti hayatta kalma oranını belirleyici biçimde artırmaktadır. Dermoskopi, pigmente lezyonların görselleştirilmesinde altın standart yöntem olarak kabul görmekle birlikte, görüntülerin yorumlanması yüksek uzmanlık gerektiren ve gözlemciler arası tutarsızlığa açık bir süreçtir. Bu bağlamda bilgisayarlı görü tabanlı otomatik sınıflandırma sistemleri klinisyenlere değerli karar destek araçları sunma potansiyeli taşımaktadır.

HAM10000 (Human Against Machine with 10000 Training Images) veri seti [1], 10.015 dermoskopik görüntüden oluşan ve yedi farklı deri lezyonu kategorisini kapsayan kapsamlı bir akademik veri tabanıdır. Veri setinin başlıca zorluğu aşırı sınıf dengesizliğidir: melanositik nevüs (nv) sınıfı 6.705 örnek ile toplam verinin %66.9'unu oluştururken, dermatofibroma (df) sınıfı yalnızca 115 örnek ile temsil edilmektedir; bu durum 58:1 oranında bir dengesizliğe işaret etmektedir. Ek olarak, farklı lezyon sınıfları arasındaki yüksek görsel benzerlik ve aynı lezyona ait birden fazla görüntünün bulunması metodolojik güçlükler ortaya çıkarmaktadır.

Bu çalışmanın amacı üç boyutludur: (1) geleneksel özellik mühendisliği tabanlı yöntemler ile derin öğrenme mimarilerini sistematik biçimde karşılaştırmak; (2) yalnızca genel doğruluğu değil, kanseri kaçırmama oranını (melanom Recall) ön planda tutan klinik odaklı bir değerlendirme gerçekleştirmek ve (3) veri artırma ile sınıf ağırlıklandırmasının model performansına etkisini ablasyon çalışmasıyla sayısal olarak ölçmek.

## II. MATERYAL VE YÖNTEM

### A. Veri Seti ve Sızıntı Önleme

Çalışmada HAM10000 dermoskopik görüntü veri seti kullanılmıştır. Veri setinde yer alan yedi sınıf ve dağılımları Tablo I'de özetlenmektedir. Standart rassal bölme yöntemi, aynı hastaya ait (aynı lesion\_id'ye sahip) birden fazla görüntünün eğitim ve test setlerine birlikte düşmesi halinde veri sızıntısına (data leakage) yol açacağından tercih edilmemiştir.

Bunun yerine StratifiedGroupKFold (n\_splits=6) ile iki aşamalı gruplu bölme uygulanmıştır: birinci aşamada test seti (%16.5, 1650 örnek) ayrılmış; ikinci aşamada kalan veri eğitim (%69.6, 6970 örnek) ve doğrulama (%13.9, 1395 örnek) setlerine bölünmüştür. Hem indeks kesişim kontrolü hem de grup sızıntı kontrolü başarıyla geçilmiştir.

### B. Geleneksel Yöntemler: Özellik Mühendisliği

k-NN modeli için hmnist\_8\_8\_RGB.csv veri setindeki 8×8 RGB piksel verileri (192 özellik) kullanılmış; ardından PCA ile 32 bileşene indirgenmiştir. Sınıf dengesizliği için yalnızca eğitim verisine SMOTE uygulanmış; KNeighborsClassifier(n\_neighbors=5) ile eğitim gerçekleştirilmiştir.

SVM modeli için hmnist\_28\_28\_L.csv veri setindeki 28×28 gri tonlamalı görüntülerden HOG (Histogram of Oriented Gradients) özellikleri çıkarılmıştır (orientations=9, pixels\_per\_cell=(7,7), cells\_per\_block=(2,2)). HOG özellik vektörleri PCA ile 128 bileşene indirgindikten sonra SVC(kernel='rbf', class\_weight='balanced') ile eğitilmiştir.

### C. Derin Öğrenme: Transfer Öğrenme Mimarileri

Üç farklı ImageNet ön-eğitilmiş mimari kullanılmış ve her biri için HAM10000'e özgü 7-sınıflı sınıflandırma başlığı eklenmiştir. Katman dondurma stratejileri Tablo II'de özetlenmektedir. Tüm modeller Adam (lr=0.0001) ve CrossEntropyLoss ile eğitilmiştir. Sınıf ağırlıkları frekansa ters orantılı hesaplanmış (df sınıfı için en yüksek

ağırlık: 13.83); aşırı öğrenme için veri artırma ve EarlyStopping (sabır=10, min. 30 epoch) uygulanmıştır. Doğrulama kaybı platoya ulaştığında öğrenme oranı ReduceLRonPlateau ile otomatik düşürülmüştür. Tüm modellerin anahtar hiperparametreleri ve

gerçekleşen eğitim süreleri Tablo III'te karşılaştırmalı olarak sunulmaktadır.

TABLE I  
HAM10000 Veri Setindeki Sınıf Dağılımı

| Kod          | Lezyon Türü            | Örnek | Oran  | Train | Val   | Test  |
|--------------|------------------------|-------|-------|-------|-------|-------|
| <b>nv</b>    | Melanositik Nevüs      | 6705  | 66.9% | 66.7% | 68.3% | 66.9% |
| <b>mel</b>   | Melanom                | 1113  | 11.1% | 11.3% | 10.0% | 11.3% |
| <b>bkl</b>   | Benign Keratoz (bkl)   | 1099  | 11.0% | 11.1% | 10.0% | 11.2% |
| <b>bcc</b>   | Bazal Hücreli Karsinom | 514   | 5.1%  | 5.1%  | 5.4%  | 5.2%  |
| <b>akiec</b> | Aktinikal Keratoz      | 327   | 3.3%  | 3.3%  | 3.9%  | 2.5%  |
| <b>vasc</b>  | Vasküler Lezyon        | 142   | 1.4%  | 1.5%  | 1.2%  | 1.3%  |
| <b>df</b>    | Dermatofibroma         | 115   | 1.1%  | 1.0%  | 1.1%  | 1.6%  |

TABLE II  
Transfer Öğrenme Mimarileri ve Katman Dondurma Stratejileri

| Model           | Dondurulan Katmanlar    | Eğitilen Katmanlar         | Toplam Param. | Eğ. Param. % |
|-----------------|-------------------------|----------------------------|---------------|--------------|
| <b>AlexNet</b>  | features (tüm conv)     | classifier (tam)           | 57.0 M        | %95.7        |
| <b>VGG16</b>    | features[0:24]          | features[24:] + classifier | 134.3 M       | %94.3        |
| <b>ResNet50</b> | conv1+bn1+layer1+layer2 | layer3+layer4+fc           | 23.5 M        | %93.9        |

TABLE III  
Tüm Modeller — Anahtar Hiperparametre ve Eğitim Süresi Karşılaştırması

| Model           | Kategori   | Temel Hiperparametre                                                                              | Optimizör / lr        | Batch × Epoch | Eğitim Süresi |
|-----------------|------------|---------------------------------------------------------------------------------------------------|-----------------------|---------------|---------------|
| <b>k-NN</b>     | Baseline   | k=5, Öklid mesafesi; PCA(n=32); SMOTE (yalnızca eğitim)                                           | —                     | —             | < 1 sn        |
| <b>SVM</b>      | Klasik ML  | RBF kernel; HOG (ori=9, ppc=(7,7), cpb=(2,2)); PCA(n=128); class_weight='balanced'                | —                     | —             | ~ 17 sn       |
| <b>AlexNet</b>  | Derin Öğr. | Aug=ON; CW (df ağırlığı=13.83); EarlyStopping(sabır=10, min_ep=30); ReduceLRonPlateau(factor=0.5) | Adam; 1e-4 → 6.25e-6  | 32 × 30       | 36.4 dk       |
| <b>VGG16</b>    | Derin Öğr. | Aug=ON; CW (df ağırlığı=13.83); EarlyStopping(sabır=10, min_ep=30); ReduceLRonPlateau(factor=0.5) | Adam; 1e-4 → 3.13e-6  | 32 × 30       | 45.0 dk       |
| <b>ResNet50</b> | Derin Öğr. | Aug=ON; CW (df ağırlığı=13.83); EarlyStopping(sabır=10, min_ep=30); ReduceLRonPlateau(factor=0.5) | Adam; 1e-4 → ~6.25e-6 | 32 × 30       | 42.4 dk       |

\* Derin öğrenme modellerinde epoch sayısı erken durdurma koşulu ile belirlenmiş olup her model tam 30 epoch tamamlamıştır. lr: öğrenme oranı; Aug: veri artırma; CW: sınıf ağırlığı.

### III. BULGULAR VE DENEYSEL SONUÇLAR

#### A. Baseline Model Performansları (Geleneksel ML)

Geleneksel makine öğrenmesi modellerinin test seti sonuçları Tablo IV'te verilmiştir. Her iki model de sınıf dengesizliği nedeniyle

çoğunluk sınıfı nevüs'e (nv) yönelme eğilimi göstermiştir. Buna karşın k-NN'in doğrulama ve test F1 skorları (0.2753 / 0.3031) tutarlı seyir izlemiş; bu durum aşırı öğrenmenin gerçekleşmediğini göstermektedir.

TABLE IV  
Geleneksel Makine Öğrenmesi Modelleri — Test Seti Performansları


| Model | Özellik Yöntemi | Makro F1 | Doğruluk | mel F1 | mel Recall | nv F1 | Val F1 |
|-------|-----------------|----------|----------|--------|------------|-------|--------|
|-------|-----------------|----------|----------|--------|------------|-------|--------|

|                  |                            |               |        |        |        |        |        |
|------------------|----------------------------|---------------|--------|--------|--------|--------|--------|
| <b>k-NN</b>      | 8×8 RGB + PCA(32) + SMOTE  | <b>0.3031</b> | 0.5206 | 0.3385 | 0.4064 | 0.7200 | 0.2753 |
| <b>SVM (HOG)</b> | 28×28 Gri + HOG + PCA(128) | 0.2477        | 0.5691 | 0.2987 | 0.3690 | 0.7750 | 0.2408 |


### B. Derin Öğrenme Modelleri: Eğitim Eğrileri

Her üç derin öğrenme modelinin Aug=ON, CW=ON konfigürasyonundaki kayıp (loss) ve doğruluk (accuracy) eğrileri sırasıyla Fig. 1, 2 ve 3'te gösterilmektedir. AlexNet 30 epoch ile erken


durma noktasına ulaşmıştır (toplam eğitim: 36.4 dk). VGG16 ve ResNet50 da 30. epoch'ta erken durdurma koşulunu tetiklemiştir; eğitim süreleri sırasıyla 45.0 dk ve ~43 dk olmuştur.



**Fig. 1.** AlexNet (Aug=ON, CW=ON) eğitim ve doğrulama kayıp ile doğruluk eğrileri (30 epoch, erken durdurma).



**Fig. 2.** VGG16 (Aug=ON, CW=ON) eğitim ve doğrulama kayıp ile doğruluk eğrileri (30 epoch, val\_acc=0.7892)



**Fig. 3.** ResNet50 (Aug=ON, CW=ON) eğitim ve doğrulama kayıp ile doğruluk eğrileri (30 epoch, val\_acc=0.8301).

### C. Derin Öğrenme Modelleri Karşılaştırması

Tablo V, üç transfer öğrenme modelinin test seti performansını kapsamlı biçimde sunmaktadır. Tabloda klinik açıdan kritik iki metrik özellikle vurgulanmıştır: melanom Recall değeri (VGG16 için en yüksek) ve Makro F1 skoru (ResNet50 için en yüksek). ResNet50'nin yüksek Makro F1'e rağmen düşük melanom Recall sergilemesi bu çalışmanın temel klinik bulgusunu oluşturmaktadır.

*Değerlendirme Metriği Notu:* mAP (mean Average Precision), ağırlıklı olarak nesne tespiti ve konumlandırma görevleri için tasarlanmış bir metriktir; temel hesabı tahmin edilen sınırlayıcı kutu (bounding box) ile gerçek kutu arasındaki IoU eşiklerine dayanmaktadır. Görüntü sınıflandırma görevlerinde ise mAP bu bileşeni

içermediğinden doğrudan uygulanamaz. Bu nedenle bu çalışmada mAP yerine iki tamamlayıcı metrik benimsenmiştir: (1) **Makro-ortalama F1 skoru** — her sınıfa eşit ağırlık veren ve azınlık sınıflarının performansını gizlemeyen metrik; HAM10000 üzerindeki temel yayınlar (Tschandl et al. [1]; Codella et al. [2]) da birincil karşılaştırma ölçütü olarak Makro F1'i kullanmıştır. (2) **AUC-ROC (One-vs-Rest)** — tüm karar eşiklerindeki ayırıştırıcı gücü özetleyen ve sınıf dengesizliğine karşı dirençli metrik; 58:1 oranlı dengesizlikte çoğunluk sınıfına aşırı yöneliş (majority bias) olmaksızın her sınıfın gerçek model kapasitesini yansıtır. Her sınıfa ait AUC değerleri Fig. 4–6'daki ROC eğrilerinde sınıf sınıf gösterilmektedir.

TABLE V  
Derin Öğrenme Modelleri — Test Seti Karşılaştırması

| Model    | Test Doğruluğu | Makro F1 | mel Recall | mel F1 | nv F1  |
|----------|----------------|----------|------------|--------|--------|
| AlexNet  | 0.7091         | 0.5501   | 0.5829     | 0.4542 | 0.8386 |
| VGG16    | 0.7691         | 0.6257   | 0.5936     | 0.5139 | 0.8778 |
| ResNet50 | 0.8303         | 0.7236   | 0.4652     | 0.5133 | 0.9142 |

#### D. Sınıf Bazlı Detaylı Performans

Tablo VI, üç modelin her sınıf için F1 değerlerini karşılaştırmalı olarak sunmaktadır. Melanom (mel) ve dermatofibroma (df) gibi azınlık sınıflarında tüm modellerin düşük F1 sergilediği, nevüs (nv) ve

vasküler lezyon (vasc) sınıflarında ise nispeten yüksek başarı elde edildiği gözlemlenmiştir.

TABLE VI  
Sınıf Bazlı F1 Skorları — Derin Öğrenme Modelleri Karşılaştırması

| Sınıf | AlexNet Pre. | AlexNet Rec. | AlexNet F1 | VGG16 F1 | VGG16 Rec. | ResNet50 F1 | Destek |
|-------|--------------|--------------|------------|----------|------------|-------------|--------|
| akiec | 0.2857       | 0.3902       | 0.3299     | 0.4819   | 0.4878     | 0.5495      | 41     |
| bcc   | 0.5333       | 0.7529       | 0.6244     | 0.6667   | 0.7059     | 0.7389      | 85     |
| bkl   | 0.5595       | 0.5109       | 0.5341     | 0.5641   | 0.5380     | 0.7167      | 184    |
| df    | 0.2609       | 0.4444       | 0.3288     | 0.4186   | 0.3333     | 0.7391      | 27     |
| mel   | 0.3720       | 0.5829       | 0.4542     | 0.5139   | 0.5936     | 0.5133      | 187    |
| nv    | 0.9144       | 0.7745       | 0.8386     | 0.8778   | 0.8623     | 0.9142      | 1104   |
| vasc  | 0.6250       | 0.9091       | 0.7407     | 0.8571   | 0.8182     | 0.8936      | 22     |

#### E. ROC Eğrileri ve AUC Analizi

Fig. 4, 5 ve 6'da AlexNet, VGG16 ve ResNet50 için One-vs-Rest yöntemiyle hesaplanan sınıf bazlı AUC-ROC eğrileri gösterilmektedir. Melanom (mel) sınıfına ait eğri her grafikte kalın çizgiyle ve farklı renkte vurgulanmaktadır. Yüksek AUC değerleri modelin

sınıflandırma gücünü yansıtırken, klinik değerlendirmede ROC eğrisinin sol üst köşeye yakınlığı belirleyici ölçüt olarak kullanılmaktadır.






Fig. 4. AlexNet One-vs-Rest AUC-ROC eğrisi. Melanom (mel) sınıfı kalın çizgiyle vurgulanmıştır. (Macro F1=0.5501, mel Recall=0.5829)



**Fig. 5.** VGG16 One-vs-Rest AUC-ROC eğrisi. Melanom (mel) sınıfı kalın çizgiyle vurgulanmıştır. (Macro F1=0.6257, mel Recall=0.5936 )




**Fig. 6.** ResNet50 One-vs-Rest AUC-ROC eğrisi. Melanom (mel) sınıfı kalın çizgiyle vurgulanmıştır. (Macro F1=0.7236 , mel Recall=0.4652)


#### F. Karmaşıklık Matrisi Analizi

Fig. 7, 8 ve 9'da üç modelin test seti karmaşıklık matrisleri ısı haritası olarak gösterilmektedir. Matrislerin köşegen elemanları doğru sınıflandırılan örnekleri, köşegen dışı elemanlar ise model hatalarını temsil etmektedir. Özellikle mel (187 test örneği) için satır


incelendiğinde modellerin nevüs sınıfına yanlış yöneliminin boyutu ortaya çıkmaktadır. AlexNet: 78 mel hatası; VGG16: 76 mel hatası; ResNet50: 100 mel hatası.



**Fig. 7.** AlexNet test seti karmaşıklık matrisi (7 sınıf). Toplam mel hatası: 78 örnek, doğruluk: %70.91.



**Fig. 8.** VGG16 test seti karmaşıklık matrisi (7 sınıf). Toplam mel hatası: 76 örnek, doğruluk: %76.91.



**Fig. 9.** ResNet50 test seti karmaşıklık matrisi (7 sınıf). Toplam mel hatası: 100 örnek, doğruluk: %83.03.

### G. Görsel Hata Analizi: Melanom Yanlış Tahminleri

Her model için gerçekte melanom (mel) olup yanlış sınıflandırılan en yüksek güvenli beş görüntü Fig. 10, 11 ve 12'de sunulmaktadır. Seçimde önce nv (nevüs) olarak tahmin edilenler, ardından en yüksek


yanlış güven skoru tercih edilmiştir. Her görselin altında gerçek etiket, tahmin ve dx\_type (tanı yöntemi: histo/consensus) bilgisi yer almaktadır.



**Fig. 10.** AlexNet — Melanom yanlış tahmin analizi (top-5, güven sıralı). Her görsel üzerinde: Gerçek: mel | Tahmin: [sınıf] ([güven]) | dx\_type. Kırmızı başlıklar.



**Fig. 11.** VGG16 — Melanom yanlış tahmin analizi (top-5, güven sıralı). Her görsel üzerinde: Gerçek: mel | Tahmin: [sınıf] ([güven]) | dx\_type. Kırmızı başlıklar.



**Fig. 12.** ResNet50 — Melanom yanlış tahmin analizi (top-5, güven sıralı). Her görsel üzerinde: Gerçek: mel | Tahmin: [sınıf] ([güven]) | dx\_type. Kırmızı başlıklar.


### H. Ablasyon Çalışması (ResNet50)

ResNet50 mimarisi üzerinde veri artırma (Aug) ve sınıf ağırlıklandırmasının (CW) etkisini ölçmek amacıyla dört konfigürasyon test edilmiştir. Tablo VII sonuçlarını özetlerken Fig. 13–15 her ablasyon konfigürasyonunun eğitim eğrilerini ve


karmaşıklık matrisini görselleştirmektedir. İki de var konfigürasyonunun sonuçları (Aug=ON, CW=ON) zaten Tablo V ve Fig. 9'da verilmiştir.

TABLE VII  
Ablasyon Çalışması — ResNet50 Dört Konfigürasyon Karşılaştırması

| Konfigürasyon                   | Veri Artırma (Aug) | Sınıf Ağırlığı (CW) | Makro F1      | mel Recall    |
|---------------------------------|--------------------|---------------------|---------------|---------------|
| İkisi de Yok (Baseline)         | OFF                | OFF                 | 0.7098        | 0.4492        |
| Sadece Veri Artırma             | ON                 | OFF                 | 0.7187        | 0.4652        |
| Sadece Sınıf Ağırlığı           | OFF                | ON                  | 0.6804        | 0.4492        |
| <b>İkisi de Var (Tam Model)</b> | <b>ON</b>          | <b>ON</b>           | <b>0.7236</b> | <b>0.4652</b> |




**Fig. 13.** ResNet50 Ablasyon — İkisi de Yok (Aug=OFF, CW=OFF): (a) Kayıp eğrisi, (b) Doğruluk eğrisi (val\_acc=0.8616), (c) Karmaşıklık matrisi. Makro F1=0.7098, mel Recall=0.4492.



**Fig. 14.** ResNet50 Ablasyon — Sadece Veri Artırma (Aug=ON, CW=OFF): (a) Kayıp eğrisi, (b) Doğruluk eğrisi, (c) Karmaşıklık matrisi. Makro F1=0.7187, mel Recall=0.4652.





**Fig. 15.** ResNet50 Ablasyon — Sadece Sınıf Ağırlığı (Aug=OFF, CW=ON): (a) Kayıp eğrisi, (b) Doğruluk eğrisi, (c) Karmaşıklık matrisi. Makro F1=0.6804, mel Recall=0.4492.

#### IV. TARTIŞMA VE KLİNİK ANALİZ

##### A. Geleneksel Yöntemlerin Sınırları

SVM ve k-NN modellerinin düşük Makro F1 skorları (sırasıyla 0.2477 ve 0.3031) beklenen bir sonuç olmakla birlikte, bu başarısızlığın klinik önemi büyüktür. HOG gibi el ile formüle edilen özellikler deri lezyonlarındaki melanom-spesifik mikro yapıları (atipik vasküler örüntüler, irregüler pigment ağı) yakalayamamaktadır. SVM'in nv dışında birçok sınıfta sıfıra yakın F1 değerleri üretmesi, class\_weight='balanced' parametresine rağmen azınlık sınıflarının doğrusal ayrılabilirliğe sahip olmadığını doğrulamaktadır.

##### B. Derinlik-Klinik Güvenlik Paradoksu (ResNet50 vs VGG16)

Çalışmanın en önemli bulgusu, ResNet50 ve VGG16 arasındaki tersinir performans ilişkisidir. ResNet50 Makro F1'de (%72.36) birinci sırada yer alırken melanom Recall değeri (%46.52) ile derin öğrenme modelleri arasında en düşük değere sahiptir. Bu paradoksun mekanizması, ResNet50'nin uzun eğitim sürecinde çoğunluk sınıfı nv'ye yönelerek overconfidence geliştirmesinde yatmaktadır: ResNet50'nin nv F1 değeri (0.9142) VGG16'nın nv F1'ine (0.8778) göre belirgin biçimde yüksektir.

Tıbbi yapay zekâ bağlamında bu sonuç temel bir ilkeyi teyit etmektedir: genel doğruluk ve Makro F1 klinik güvenilirliğin tek başına yeterli göstergesi değildir. Yanlış negatif (kansersiz hastaya sağlıklı demek) riski ölümcül olduğundan, melanom Recall değeri yüksek olan VGG16'nın klinik karar destek sisteminde tercih edilmesi daha güvenli bir yaklaşımdır.

##### C. Ablasyon Bulguları

Ablasyon çalışması, veri artırmanın Makro F1'e sınırlı ama tutarlı katkı sağladığını (+0.0089) ortaya koymuştur. Sınıf ağırlıklandırması tek başına uygulandığında Makro F1'i beklenmedik biçimde düşürmüştü (0.7098'den 0.6804'e); bu durum ağırlıklandırmanın veri artırmayla sinerjik çalıştığına işaret etmektedir. Her iki tekniğin birlikte uygulandığı tam modelde en yüksek Makro F1 (0.7236) ve melanom Recall (0.4652) elde edilmiştir.

##### D. Görsel Hata Analizi ve Tanısal Belirsizlik

Melanom yanlış tahminlerinin görsel analizi, hataların büyük bölümünün mel→nv yönünde gerçekleştiğini göstermiştir. HAM10000'deki dx\_type sütununa bakıldığında, bu hataların önemli kısmının histopatolojik değil uzman uzlaşısı (consensus) etiketli örneklerde yoğunlaştığı görülmektedir. Deneyimli dermatologlar arasında dahi biyopsi olmadan melanom ile nevüs arasındaki sınırın çizilemediği vakalarda modelin yanılması algoritmik değil medikal verinin kendi doğasındaki belirsizliğin yansımasıdır.

##### E. Literatür Kıyası

Çalışmamızdan elde edilen sonuçları geniş bir bağlama oturtabilmek için literatürde HAM10000 ve benzer dermoskopik veri setleriyle yakın zamanda gerçekleştirilmiş güncel hakemli çalışmaların bulguları ile karşılaştırma yapılmıştır:

Moradi ve Shaikh [10]: Doğrudan HAM10000 veri setinin dengeli hale getirilmiş bir versiyonu üzerinde ResNet50 kullanarak %92.31 doğrulama doğruluğu ve 0.9198 F1-skoru raporlamışlardır. Bizim ResNet50 modelimiz (Makro F1: 0.7236) daha düşük bir genel skor sergilemekle birlikte, sentetik (oversampled) test seti yerine modelin gerçek klinik dengesizliğe (58:1 oranına) maruz bırakıldığı zorlu bir değerlendirmeden geçmesi bu farklılığı açıklamaktadır.

Kajale ve ark. [11]: HAM10000 üzerinde düşük çözünürlüklü (32x32) ancak dengeli örneklenmiş alt veri setiyle (3500 görüntü) tasarladıkları hafif CNN modeliyle %94 doğruluk elde etmişlerdir. Bizim çalışmamız ise 224x224 yüksek çözünürlük kullanarak lezyon içi mikro yapıları (ağ dokusu) hesaba katan daha detaylı bir mimari kullanmaktadır.

Mustafa ve ark. [12]: Model Checkpoint ve Dropout yaklaşımları ekledikleri özel CNN mimarileri ile HAM10000 üzerinde %97.78 doğruluğa ulaşmış olsalar da, yazar grubunun F1 skorlarında dermatofibrom (df) için 0.10 oranında kaldığı görülmüştür. Bu bağlamda bizim çalışmamız, genel accuracy değerini şişirmek yerine azınlık sınıflarının başarımına odaklanan Makro F1 ölçütüyle çok daha gerçekçi bir yaklaşım sunmaktadır.

Shakya ve ark. [13] ile Mohamed ve ark. [14]: ISIC/Kaggle gibi veri setlerinde sırasıyla MobileNetV2 tabanlı ve Ensemble yaklaşımlarla %92.57 ile %97 doğruluk bildirmişlerdir. Ancak her iki çalışma da görevi yedi sınıflı zorlu bir tasnif yerine "İkili Sınıflandırma

(Benign/Malignant)" problemine indirgediğinden sonuçların HAM10000 deki kompleks 7 sınıf başarımla doğrudan yarışması beklenemez.

Sonuç olarak; literatürdeki çalışmalar ağırlıklı olarak sentetik şekilde veri dengelemeye (test seti dahil) veya problemi ikili sınıfa indirmeye giderek genel doğruluğu %90 ların üzerine çıkarmaktadır.

Önerdiğimiz yaklaşım ise dengesiz sınıf verisini test aşamasında da olduğu gibi koruyarak "doğruluk paradoksunu" kırmış, klinik açıdan asıl kritik nokta olan "Melanom Recall" yeteneği üzerinde tarafsız ve metodolojik olarak sağlam bir karşılaştırma platformu oluşturmuştur.

## V. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada HAM10000 dermoskopik veri setinde geleneksel ve derin öğrenme yöntemleri karşılaştırılmıştır. Veri sızıntısı önleyici StratifiedGroupKFold bölme, sınıf ağırlıklandırması ve ablasyon analizi içeren metodolojik çerçeve ile şu sonuçlara ulaşılmıştır: (1) Derin öğrenme modelleri geleneksel yöntemleri ezici biçimde geçmiştir. (2) ResNet50 genel Makro F1'de lider olurken VGG16 klinik güvenilirlik açısından daha üstündür. (3) 58:1 sınıf dengesizliği mevcut stratejilerle tam anlamıyla çözülmemiştir.

Gelecek çalışmalarda şu yöntemler önerilmektedir: ResNet50 ve VGG16'yı bir ensemble modelinde birleştirmek; Focal Loss ya da Class-Balanced Loss kullanmak; GAN tabanlı sentetik azınlık sınıfı üretimi gerçekleştirmek ve dx\_type bilgisini güven ağırlığı olarak eğitim sürecine entegre etmek.

## KAYNAKÇA

- [1] P. Tschandl, C. Rosendahl, H. Kittler, "The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions," *Sci. Data*, vol. 5, Art. no. 180161, 2018, doi: 10.1038/sdata.2018.161.
- [2] N. Codella et al., "Skin lesion analysis toward melanoma detection 2018: A challenge hosted by the International Skin Imaging Collaboration (ISIC)," 2019, arXiv:1902.03368.
- [3] K. Simonyan, A. Zisserman, "Very Deep Convolutional Networks for Large-Scale Image Recognition," in *Proc. ICLR*, 2015, arXiv:1409.1556.
- [4] K. He, X. Zhang, S. Ren, J. Sun, "Deep Residual Learning for Image Recognition," in *Proc. CVPR*, 2016, pp. 770-778.
- [5] A. Krizhevsky, I. Sutskever, G. E. Hinton, "ImageNet Classification with Deep CNNs," in *Proc. NeurIPS*, 2012, pp. 1097-1105.
- [6] N. V. Chawla, K. W. Bowyer, L. O. Hall, W. P. Kegelmeyer, "SMOTE: Synthetic Minority Over-sampling Technique," *J. Artif. Intell. Res.*, vol. 16, pp. 321-357, 2002.
- [7] N. Dalal, B. Triggs, "Histograms of Oriented Gradients for Human Detection," in *Proc. IEEE CVPR*, 2005, vol. 1, pp. 886-893.
- [8] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825-2830, 2011.
- [9] A. Paszke et al., "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in *Proc. NeurIPS*, 2019, vol. 32.
- [10] S. Moradi and M. Shaikh, "Transfer learning based skin cancer detection using convolutional neural networks," in *Proc. 9th Int. Conf. Intell. Inform. Biomed. Sci. (ICIIBMS)*, Nov. 2024, pp. 501-510, doi: 10.1109/ICIIBMS62405.2024.10792809.
- [11] P. Kajale, P. Dhavane, A. Dangat, H. Gawali et al., "Skin cancer lesion detection using CNN with HAM10000 dataset," in *Proc. IEEE Pune Sect. Int. Conf. (PuneCon)*, Pune, India, 2025, pp. 1-6, doi: 10.1109/PuneCon63835.2025.11379036.
- [12] M. M. Musthafa, T. R. Mahesh, V. K. Vinoth, and S. Guluwadi, "Enhanced skin cancer diagnosis using optimized CNN architecture and checkpoints for automated dermatological lesion classification," *BMC Med. Imaging*, vol. 24, Art. no. 201, Aug. 2024, doi: 10.1186/s12880-024-01356-8.
- [13] M. Shakyia, R. Patel, and S. Joshi, "A comprehensive analysis of deep learning and transfer learning techniques for skin cancer classification," *Sci. Rep.*, vol. 15, Art. no. 4633, Feb. 2025, doi: 10.1038/s41598-024-82241-w.
- [14] I. Mohamed, D. Ashraf, and N. Elquersh, "Classification of skin cancer images utilizing transfer learning approaches," in *Proc. Int. Conf. Mach. Intell. Smart Innov. (ICMISI)*, 2025, pp. 373-380.